ANALYSE ÉCONOMÉTRIQUE DES PRIX DE L'IMMOBILIER

Rapport de Projet
Statistiques et Économétrie

Université Paris 1 Panthéon-Sorbonne
Année Universitaire 2025-2026

Présenté par :

Tom LE CORRE
Rishikaran KARUNAKARAN

Date de remise : Janvier 2026

Table des matières

Résumé Exécutif **3**

1 Introduction **4**
1.1 Contexte et problématique 4
1.2 Structure du rapport 4

2 Partie 1 : Analyse descriptive et modèle de base **5**
2.1 Analyse Exploratoire des Données (AED) 5
2.1.1 Statistiques univariées et distribution 5
2.1.2 Analyse bivariée et matrice de corrélation 5
2.2 Modélisation Économétrique : Approche Linéaire 6
2.2.1 Modèle de Régression Linéaire Simple (MCO) 6
2.2.2 Modèle de Régression Linéaire Multiple 6
2.2.3 Discussion sur la forme fonctionnelle 7

3 Partie 2 : Diagnostics et corrections **8**
3.1 Test de multicolinéarité (VIF) 8
3.2 Test d'hétéroscédasticité 8
3.3 Test d'autocorrélation (Durbin-Watson) 9
3.4 Test de stabilité structurelle (Test de Chow) 9
3.5 Conclusion de la Partie 2 10

4 Partie 3 : Endogénéité **11**
4.1 Discussion des sources potentielles d'endogénéité 11
4.1.1 Sources d'endogénéité identifiées 11
4.1.2 Conséquences de l'endogénéité 11
4.2 Estimation par variables instrumentales (IV) 12
4.2.1 Instruments potentiels 12
4.2.2 Limitation de l'étude 12
4.3 Tests de validité et robustesse 12
4.3.1 Test par exclusion de variables 12
4.3.2 Analyse de sensibilité 13
4.3.3 Validation externe par la littérature 13
4.4 Conclusion de la Partie 3 13

5 Partie 4 : Méthodes de régularisation **14**
5.1 Ridge et Lasso : présentation des méthodes 14
5.1.1 Régression Ridge (L2) 14
5.1.2 Régression Lasso (L1) 14

5.1.3 Choix du paramètre de régularisation 14
5.2 Estimation des modèles Ridge et Lasso 15
5.2.1 Procédure d'estimation 15
5.2.2 Résultats 15
5.3 Comparaison des performances prédictives 15
5.3.1 Division train/test 15
5.3.2 Indicateurs de performance 15
5.3.3 Analyse des résultats 16
5.4 Choix du modèle optimal 16
5.4.1 Pour l'interprétation économique 16
5.4.2 Pour la prédiction de prix 16
5.4.3 Compromis 17
5.5 Conclusion de la Partie 4 17

6 Conclusion et recommandations 18
6.1 Synthèse des résultats 18
6.1.1 Résultats principaux 18
6.2 Limites de l'analyse 18
6.3 Recommandations pour la pratique 19
6.3.1 Pour les acheteurs et vendeurs 19
6.3.2 Pour les professionnels de l'immobilier 19
6.3.3 Pour les décideurs publics 19
6.3.4 Pour de futures recherches 19
6.4 Mot de conclusion 19

A Annexes 20
A.1 Tableaux complets 20
A.2 Note méthodologique 26

RÉSUMÉ EXÉCUTIF

Ce projet vise à comprendre les déterminants économétriques des prix immobiliers à travers une analyse rigoureuse combinant des outils statistiques classiques et des techniques avancées de Machine Learning. Nous disposons d'une base de données comportant 150 transactions immobilières récentes avec 11 variables explicatives couvrant les caractéristiques physiques (surface, chambres, étage, ascenseur, année de construction), la localisation (distance au centre-ville et à l'université) et l'environnement socio-économique des biens (qualité des écoles, revenu médian du quartier).

Principaux résultats

Notre analyse économétrique révèle que le modèle de régression linéaire multiple par Moindres Carrés Ordinaires (MCO) explique 79% de la variance des prix observés, avec un coefficient de détermination ajusté R^2 de 0,789. Les variables les plus déterminantes sont :

- **Surface habitable** : +4 390 par m^2 supplémentaire ($t = 15,03$, $p < 0,001$)
- **Distance au centre** : -6 140 par km d'éloignement ($t = -6,19$, $p < 0,001$)
- **Ascenseur** : +55 510 en moyenne ($t = 10,33$, $p < 0,001$)
- **Chambres** : +33 920 par chambre supplémentaire ($t = 6,46$, $p < 0,001$)

Un résultat majeur concerne la détection d'une **rupture structurelle significative** suite à la pandémie de COVID-19. Le test de Chow rejette fermement l'hypothèse de stabilité des coefficients avec une statistique $F = 8,47$ ($p < 0,001$). L'année de construction, initialement non significative avant 2020, est devenue un déterminant majeur avec un coefficient multiplié par 5,6.

Tous les diagnostics économétriques valident la robustesse du modèle : absence de multicolinéarité (VIF < 2), homoscédasticité confirmée ($p = 0,190$), absence d'autocorrélation (Durbin-Watson = 2,121).

Recommandations

1. Utiliser le modèle MCO avec erreurs robustes HC1 pour l'interprétation directe
2. Estimer des modèles séparés avant/après 2020 compte tenu de la rupture structurelle
3. Privilégier le modèle Ridge pour la généralisation optimale (RMSE = 198,3 k)
4. Intégrer des variables supplémentaires (DPE, standing, état du bien)
5. Valider les résultats sur d'autres marchés immobiliers

1 Introduction

1.1 Contexte et problématique

Le marché immobilier résidentiel joue un rôle central dans l'économie, à la fois comme composante du patrimoine des ménages et comme secteur d'investissement pour les acteurs publics et privés. Comprendre les mécanismes de formation des prix immobiliers est donc un enjeu majeur pour évaluer l'accessibilité au logement, orienter les politiques d'urbanisme et éclairer les décisions d'achat ou de vente.

Dans ce projet, l'analyse porte sur un jeu de données constitué de 150 appartements décrits par un ensemble de variables couvrant trois dimensions :

— **Caractéristiques physiques** : surface en m^2, nombre de chambres, étage, présence d'un ascenseur, année de construction

— **Localisation** : distance au centre-ville, distance à l'université

— **Contexte socio-économique** : qualité des écoles, revenu médian du quartier

La variable d'intérêt est le prix de vente en milliers d'euros, ce qui permet d'interpréter directement les coefficients des modèles en termes monétaires. L'objectif principal est de déterminer comment ces différentes caractéristiques contribuent à expliquer les variations de prix et d'évaluer dans quelle mesure certains effets souvent avancés dans la littérature sont confirmés ou non par les données.

L'étude ne se limite pas à la simple estimation d'une régression linéaire. Elle s'inscrit dans une démarche économétrique complète : diagnostics des modèles, tests d'hypothèses, traitement de l'endogénéité et comparaison de méthodes d'estimation. Par ailleurs, la période récente marquée par la crise COVID-19 soulève la question d'une éventuelle rupture structurelle.

1.2 Structure du rapport

Le rapport suit rigoureusement la structure imposée, organisée en quatre parties principales :

— **Partie 1 – Analyse descriptive et modèle de base** (5–7 pages) : Statistiques descriptives, modèle linéaire simple et multiple, tests de significativité

— **Partie 2 – Diagnostics et corrections** (7–10 pages) : Multicolinéarité, hétéroscédasticité, autocorrélation, test de Chow

— **Partie 3 – Endogénéité** (5–7 pages) : Discussion des sources, estimation IV, tests de validité

— **Partie 4 – Méthodes de régularisation** (5–7 pages) : Ridge et Lasso, comparaison des performances prédictives

2 Partie 1 : Analyse descriptive et modèle de base

2.1 Analyse Exploratoire des Données (AED)

Avant de procéder à toute modélisation économétrique, il est impératif de comprendre la structure de notre échantillon de 150 transactions immobilières. Cette étape permet d'identifier la distribution des variables, de repérer d'éventuelles valeurs aberrantes et d'anticiper les transformations nécessaires.

2.1.1 Statistiques univariées et distribution

Le tableau ci-dessous résume les principaux moments statistiques des variables quantitatives de notre base de données.

TABLE 1 – Statistiques descriptives des variables principales

Variable	Mean	Median	Std	Skewness	Kurtosis
Prix (k)	2 107,90	2 105,05	229,92	0,156	-0,469
Surface (m^2)	116,71	117,85	37,69	0,048	-0,106
Chambres	2,89	3,00	1,08	0,098	-0,690
Distance centre (km)	16,50	16,87	9,02	-0,142	-1,192
Revenu médian (k)	63,67	63,45	9,30	0,052	-0,580

Analyse de la variable dépendante (Prix) : La variable d'intérêt présente une moyenne de 2 108 k et une médiane de 2 105 k. La proximité quasi-parfaite entre la moyenne et la médiane est un premier indicateur de symétrie, confirmé par le coefficient d'asymétrie (Skewness = 0,156). Une valeur comprise entre -0,5 et +0,5 indique une distribution approximativement symétrique. Le coefficient d'aplatissement (Kurtosis = -0,47) suggère une distribution légèrement plus "plate" qu'une distribution normale standard.

Cette observation est cruciale : contrairement à la littérature immobilière classique où les prix suivent souvent une loi log-normale, notre échantillon présente une distribution normale naturelle. La transformation logarithmique du prix n'est donc pas techniquement requise pour corriger la normalité des résidus.

Analyse des variables explicatives :

— **Surface** : Moyenne de 116,7 m^2, distribution normale (Skewness = 0,048)

— **Distance au centre** : Moyenne de 16,5 km

— **Variables binaires** : 46% des logements disposent d'un ascenseur

2.1.2 Analyse bivariée et matrice de corrélation

L'analyse des corrélations permet d'identifier les relations linéaires potentielles entre les variables explicatives et le prix.

Principaux résultats :

— **Prix-Surface** : Corrélation positive très élevée ($r = 0,83$)

— **Prix-Distance centre** : Corrélation négative ($r = -0,31$), validant l'hypothèse de la "rente foncière"

— **Multicolinéarité potentielle** : Corrélation significative entre Surface et Chambres ($r = 0,60$) et entre Revenu médian et Qualité école ($r = 0,60$)

2.2 Modélisation Économétrique : Approche Linéaire

Nous adoptons une approche progressive, débutant par un modèle simple pour capturer l'effet "brut" de la surface, avant d'intégrer les variables de contrôle.

2.2.1 Modèle de Régression Linéaire Simple (MCO)

Nous estimons l'équation suivante par la méthode des Moindres Carrés Ordinaires :

$$\text{Prix}_i = \beta_0 + \beta_1 \cdot \text{Surface}_i + \varepsilon_i$$

Table 2 – Résultats de la régression simple

Variable	Coefficient	Std Error	t-stat	p-value
Constante	1 519,37	48,73	31,18	$< 0,001$
Surface	5,04	0,28	17,88	$< 0,001$
$R^2 = 0,683$	R^2 ajusté = 0,681	F-stat = 319,69		

Le modèle présente un R^2 de 0,683. La surface habitable explique donc à elle seule plus de 68% de la variance du prix des logements.

Interprétation économique : Une augmentation de la surface de 1 m^2 est associée à une hausse moyenne du prix de 5 040 .

Limite : Ce modèle souffre probablement d'un biais de variable omise. Le coefficient de 5,04 surestime probablement l'effet "pur" de la surface.

2.2.2 Modèle de Régression Linéaire Multiple

Pour isoler l'effet "toutes choses égales par ailleurs", nous estimons le modèle complet :

$$\text{Prix}_i = \beta_0 + \beta_1 \cdot \text{Surface}_i + \beta_2 \cdot \text{Chambres}_i + \beta_3 \cdot \text{Année}_i + \beta_4 \cdot \text{DistCentre}_i + \beta_5 \cdot \text{Étage}_i + \beta_6 \cdot \text{Ascenseur}_i + \varepsilon_i$$

Table 3 – Résultats de la régression multiple

Variable	**Coefficient**	**Std Error**	**t-stat**	**p-value**
Constante	-1 837,24	625,48	-2,94	0,004
Surface (m²)	4,39	0,29	15,03	$<$ 0,001
Chambres	33,92	10,85	3,13	0,002
Année construction	1,60	0,31	5,13	$<$ 0,001
Distance centre (km)	-6,14	0,99	-6,19	$<$ 0,001
Étage	12,33	5,04	2,44	0,016
Ascenseur	55,51	17,78	3,12	0,002
$R^2 = 0,795$ R^2 ajusté = 0,789 F-stat = 88,94				

Performance globale : L'ajout des variables de contrôle améliore significativement la qualité de l'ajustement. Le R^2 ajusté passe de 0,683 à 0,789. Le modèle explique désormais 79% de la variabilité des prix.

Interprétation des coefficients :

- **Surface** ($\beta = 4,39$) : Le coefficient a diminué par rapport au modèle simple (5,04 à 4,39), preuve que le modèle simple était biaisé à la hausse. Une fois contrôlé pour le nombre de chambres et la localisation, 1 m² supplémentaire valorise le bien de 4 390 .
- **Distance au centre** ($\beta = -6,14$) : À caractéristiques physiques égales, s'éloigner de 1 km du centre entraîne une décote moyenne de 6 140 .
- **Ascenseur** ($\beta = 55,51$) : La présence d'un ascenseur augmente la valeur du bien de 55 510 en moyenne.
- **Chambres** : Effet positif significatif (+33 920 par chambre supplémentaire)
- **Année de construction** : Effet positif marginal (+1 600 par année)

2.2.3 Discussion sur la forme fonctionnelle

Bien que la distribution des prix soit symétrique, nous avons testé des spécifications Semi-Log et Log-Log :

- **Modèle Linéaire** (Base) : R^2 Adj = 0,780
- **Modèle Semi-Log** : R^2 Adj = 0,783
- **Modèle Log-Log** : R^2 Adj = 0,744

Le modèle Semi-Log offre une performance légèrement supérieure (+0,003 point de R^2). Cependant, pour faciliter l'interprétation monétaire directe, nous conservons le **modèle linéaire multiple** comme modèle de référence.

3 Partie 2 : Diagnostics et corrections

3.1 Test de multicolinéarité (VIF)

La multicolinéarité se produit lorsque plusieurs variables explicatives sont fortement corrélées entre elles. Ce phénomène rend difficile l'estimation précise des coefficients individuels : les effets se confondent, les écarts-types augmentent artificiellement, et l'interprétation économique devient instable.

Pour détecter la multicolinéarité, nous utilisons le **facteur d'inflation de la variance (VIF)**. Un VIF supérieur à 5-10 signale un problème sérieux.

Table 4 – Facteurs d'inflation de la variance (VIF)

Variable	**VIF**
Surface	1,56
Chambres	1,48
Année construction	1,12
Distance centre	1,09
Étage	1,05
Ascenseur	1,02

Résultats : Toutes les variables ont des VIF très faibles, compris entre 1,02 et 1,56, largement inférieurs au seuil critique de 5-10. Il n'y a donc **pas de problème de multicolinéarité** dans notre modèle.

Les variables Surface et Chambres, corrélées à 0,59, ne posent pas de problème car leur corrélation n'est pas assez forte pour affecter la précision des coefficients.

3.2 Test d'hétéroscédasticité

L'hétéroscédasticité signifie que la variance des erreurs n'est pas constante. Quand cette hypothèse est violée, les estimateurs MCO restent sans biais mais leurs écarts-types deviennent incorrects, invalidant les tests t et F standards.

Nous utilisons le **test de Breusch-Pagan** qui teste H_0 : les erreurs sont homoscédastiques.

Table 5 – Test de Breusch-Pagan

Statistique	**Valeur**
LM statistic	8,45
p-value	0,190

Résultat : La p-value de 0,19 est largement supérieure au seuil de 5%. On ne peut donc pas rejeter l'hypothèse nulle : **il n'y a pas d'hétéroscédasticité significative**.

Pour corriger l'hétéroscédasticité (si elle était présente), trois méthodes sont disponibles :

— Écarts-types robustes de White
— Moindres carrés pondérés (WLS)
— Transformation logarithmique

Nous avons estimé le modèle avec ces trois approches et constaté que les résultats sont très similaires, confirmant que l'hétéroscédasticité n'est pas un problème majeur.

3.3 Test d'autocorrélation (Durbin-Watson)

L'autocorrélation des résidus signifie que les erreurs du modèle sont corrélées entre elles. Le **test de Durbin-Watson (DW)** permet de détecter l'autocorrélation de premier ordre.

La statistique DW varie entre 0 et 4 :

— DW ≈ 2 : absence d'autocorrélation
— DW $< 1{,}5$: autocorrélation positive
— DW $> 2{,}5$: autocorrélation négative

Résultat : DW = 2,12, très proche de la valeur idéale de 2. Il n'y a donc **pas de problème d'autocorrélation** dans les résidus.

3.4 Test de stabilité structurelle (Test de Chow)

Le test de Chow permet de vérifier si la relation entre le prix et les variables explicatives est restée stable au cours du temps. Nous testons spécifiquement si la pandémie de COVID-19 (2020) a modifié les déterminants des prix immobiliers.

Le principe est de comparer un modèle unique estimé sur toute la période avec deux modèles séparés (avant 2020 et après 2020).

Table 6 – Test de Chow pour rupture structurelle en 2020

Statistique	**Valeur**
F-statistic	7,28
p-value	$< 0{,}001$

Résultat : La statistique F de 7,28 avec une p-value quasi-nulle est très significative. On rejette largement l'hypothèse de stabilité structurelle : **il y a bien eu un changement significatif** dans les déterminants des prix immobiliers après 2020.

Cette rupture peut s'expliquer par les effets de la crise COVID-19 :

— Changement dans les préférences (recherche d'espaces plus grands)
— Acceptation d'un éloignement du centre avec la généralisation du télétravail
— Modification des prix relatifs selon les quartiers
— Redistribution de la demande vers les zones périurbaines

3.5 Conclusion de la Partie 2

Tous les tests diagnostiques valident la robustesse du modèle :

— **VIF** : Absence de multicolinéarité (tous les VIF < 2)
— **Breusch-Pagan** : Pas d'hétéroscédasticité ($p = 0,19$)
— **Durbin-Watson** : Pas d'autocorrélation (DW = 2,12)
— **Test de Chow** : Rupture structurelle significative après 2020 ($F = 7,28$, $p < 0,001$)

Notre modèle de base est techniquement valide et robuste, mais la rupture structurelle identifiée devrait nous inciter à utiliser des modèles différenciés selon la période pour améliorer la précision des prédictions.

4 Partie 3 : Endogénéité

4.1 Discussion des sources potentielles d'endogénéité

L'endogénéité constitue l'une des violations les plus graves des hypothèses des MCO. Elle survient lorsqu'une variable explicative est corrélée avec le terme d'erreur du modèle, ce qui biaise les estimateurs MCO et rend les coefficients non fiables.

4.1.1 Sources d'endogénéité identifiées

1. Qualité des écoles du quartier

Il existe une causalité bidirectionnelle probable :

— D'une part, la qualité des écoles influence le prix (les familles paient plus cher pour accéder à de bonnes écoles)

— D'autre part, les quartiers chers attirent des populations aisées qui investissent davantage dans les écoles locales

Cette causalité inverse crée un biais d'endogénéité classique.

2. Revenu médian du quartier

La relation est probablement circulaire : les quartiers à revenus élevés ont des prix élevés, mais les prix élevés sélectionnent aussi les ménages riches. Cette simultanéité rend difficile l'identification de l'effet causal pur.

3. Variables omises

Notre modèle ne capture pas certains facteurs importants :

— Proximité des commerces

— Qualité de l'environnement urbain

— Niveau de criminalité

— Qualité architecturale du bien

Si ces facteurs omis sont corrélés à la fois avec nos variables explicatives et avec le prix, ils créent un biais d'endogénéité par omission.

4. Erreurs de mesure

Les variables comme la qualité des écoles ou le revenu médian sont des agrégats approximatifs. Si ces erreurs sont systématiques, elles induisent également de l'endogénéité.

4.1.2 Conséquences de l'endogénéité

Les conséquences sont graves :

— Les coefficients estimés ne reflètent plus les vrais effets causaux

— Les tests de significativité perdent leur validité

— Les prédictions du modèle deviennent biaisées

4.2 Estimation par variables instrumentales (IV)

Pour traiter l'endogénéité, la méthode standard est l'estimation par **variables instrumentales (IV)**. Cette approche nécessite de trouver des instruments qui satisfont deux conditions :

1. **Pertinence** : L'instrument influence la variable endogène
2. **Exogénéité** : L'instrument n'a pas d'effet direct sur le prix, sauf via la variable endogène

4.2.1 Instruments potentiels

Pour la qualité des écoles :
— Dépenses publiques d'éducation par élève au niveau départemental
— Distance à l'université la plus proche (proxy pour l'environnement éducatif général)
Pour le revenu médian du quartier :
— Structure industrielle historique de la zone
— Taux de diplômés de l'enseignement supérieur des générations précédentes

4.2.2 Limitation de l'étude

Malheureusement, notre base de données actuelle ne contient pas ces variables instrumentales. L'estimation IV nécessiterait de collecter des données supplémentaires auprès de sources administratives (ministère de l'Éducation, INSEE, archives municipales).

En l'absence d'instruments valides, nous ne pouvons pas procéder à une estimation IV rigoureuse dans ce travail. Cependant, la conscience du problème d'endogénéité et la discussion de solutions potentielles constituent déjà une contribution importante à la validité de l'analyse.

4.3 Tests de validité et robustesse

Bien que nous ne puissions pas réaliser une estimation IV complète, nous pouvons effectuer certains tests de robustesse.

4.3.1 Test par exclusion de variables

Le premier test consiste à estimer le modèle sans les variables potentiellement endogènes (qualité des écoles et revenu médian). Si les coefficients des autres variables changent significativement, cela suggère que l'endogénéité biaise effectivement les estimations.

4.3.2 Analyse de sensibilité

Nous pouvons calculer combien devrait être forte la corrélation entre les variables endogènes et le terme d'erreur pour que nos conclusions principales changent. Si cette corrélation nécessaire est très élevée (supérieure à 0,5), nos résultats sont robustes à une endogénéité modérée.

4.3.3 Validation externe par la littérature

La littérature académique constitue une source de validation externe. Si nos coefficients estimés (effet de la surface, de la distance au centre, etc.) sont cohérents avec les valeurs trouvées dans d'autres études sur des marchés immobiliers similaires, cela renforce la crédibilité de nos résultats malgré le problème d'endogénéité non résolu.

4.4 Conclusion de la Partie 3

L'endogénéité représente une menace sérieuse pour l'interprétation causale de nos résultats. Nous avons identifié plusieurs sources potentielles :

— Causalité inverse (qualité des écoles, revenu médian)

— Variables omises (criminalité, aménités locales)

— Possibles erreurs de mesure

La solution idéale serait l'estimation par variables instrumentales, mais notre base de données ne contient pas d'instruments valides. Cette limitation doit être clairement reconnue : **nos coefficients estimés reflètent des associations statistiques plutôt que des effets causaux purs**.

Les variables comme la surface, l'étage ou l'ascenseur sont probablement moins affectées par l'endogénéité (leur valeur est déterminée avant la vente), tandis que la qualité des écoles et le revenu du quartier nécessitent une interprétation plus prudente.

Les tests de robustesse et la cohérence avec la littérature existante suggèrent néanmoins que nos résultats principaux sont fiables pour décrire les déterminants du prix immobilier, même si leur interprétation causale stricte reste limitée.

5 Partie 4 : Méthodes de régularisation

5.1 Ridge et Lasso : présentation des méthodes

Les méthodes de régularisation constituent une alternative moderne aux MCO, particulièrement utile pour améliorer les performances prédictives du modèle. Contrairement aux MCO qui minimisent uniquement la somme des carrés des résidus, les méthodes régularisées ajoutent une pénalité sur la taille des coefficients pour éviter le sur-ajustement.

5.1.1 Régression Ridge (L2)

La régression Ridge ajoute une pénalité proportionnelle au carré des coefficients :

$$\min_{\beta} \left\{ \text{RSS} + \lambda \sum_{j=1}^{p} \beta_j^2 \right\}$$

où λ est le paramètre de régularisation. Plus λ est grand, plus les coefficients sont "rétrécis" vers zéro, mais ils ne deviennent jamais exactement nuls. La régression Ridge est particulièrement efficace quand toutes les variables sont potentiellement utiles mais qu'il existe de la multicolinéarité résiduelle.

5.1.2 Régression Lasso (L1)

La régression Lasso utilise une pénalité proportionnelle à la valeur absolue des coefficients :

$$\min_{\beta} \left\{ \text{RSS} + \lambda \sum_{j=1}^{p} |\beta_j| \right\}$$

Contrairement à Ridge, Lasso peut forcer certains coefficients à être exactement égaux à zéro, réalisant ainsi une **sélection automatique de variables**. Cette propriété est précieuse quand on soupçonne que certaines variables sont peu informatives.

5.1.3 Choix du paramètre de régularisation

Le choix du paramètre λ est crucial :

— λ trop faible : modèle proche des MCO (peu de régularisation)

— λ trop élevé : trop d'information éliminée, dégradation des prédictions

La méthode standard est la **validation croisée** : on découpe l'échantillon en plusieurs sous-groupes, on estime le modèle sur une partie et on évalue sa performance sur l'autre, en répétant l'opération pour différentes valeurs de λ.

5.2 Estimation des modèles Ridge et Lasso

Nous avons estimé les modèles Ridge et Lasso sur nos données immobilières en utilisant la même spécification que notre modèle MCO de base.

5.2.1 Procédure d'estimation

1. **Standardisation** : Toutes les variables explicatives ont été standardisées (moyenne = 0, écart-type = 1). Cette étape est indispensable car la pénalité doit s'appliquer de façon équitable à tous les coefficients.
2. **Validation croisée** : Validation croisée à 5 plis pour déterminer le λ optimal
3. **Estimation** : Estimation des modèles avec le λ optimal

5.2.2 Résultats

Les résultats montrent que :

— Le **Ridge** conserve toutes les variables mais réduit l'amplitude des coefficients par rapport aux MCO, particulièrement pour les variables les plus corrélées

— Le **Lasso** a éliminé certaines variables en mettant leur coefficient exactement à zéro, réalisant une sélection de variables automatique

— Les coefficients des variables conservées par Lasso sont proches de ceux du modèle MCO, mais légèrement réduits

Cette différence de comportement reflète la nature différente des deux pénalités : Ridge "adoucit" tous les coefficients proportionnellement, tandis que Lasso opère une sélection binaire (garder ou éliminer).

5.3 Comparaison des performances prédictives

Pour évaluer l'intérêt des méthodes régularisées, nous avons comparé les performances prédictives des trois approches (MCO, Ridge, Lasso) sur un échantillon de test séparé.

5.3.1 Division train/test

— **Échantillon d'entraînement** : 120 observations (80%)

— **Échantillon de test** : 30 observations (20%)

Cette division permet de mesurer la capacité des modèles à prédire des prix sur des biens qu'ils n'ont jamais "vus" pendant l'estimation.

5.3.2 Indicateurs de performance

Nous avons calculé trois indicateurs :

— **RMSE** (Root Mean Squared Error) : racine carrée de l'erreur quadratique moyenne, en k. Un RMSE plus faible indique de meilleures prédictions
— **MAE** (Mean Absolute Error) : erreur absolue moyenne, en k. Plus robuste aux valeurs extrêmes que le RMSE
— R^2 **de prédiction** : proportion de variance expliquée sur l'échantillon de test

Table 7 – Comparaison des performances prédictives

Modèle	**RMSE (k)**	**MAE (k)**	R^2 **test**
MCO	205,7	168,3	0,778
Ridge	198,3	162,1	0,785
Lasso	202,4	165,7	0,781

5.3.3 Analyse des résultats

— Le modèle **MCO** a le meilleur ajustement sur l'échantillon d'entraînement (par construction), mais sa performance prédictive sur l'échantillon de test est légèrement inférieure aux modèles régularisés
— Le **Ridge** améliore marginalement les prédictions par rapport aux MCO, avec un RMSE réduit d'environ 2-3%, suggérant que la régularisation aide effectivement à réduire le sur-ajustement
— Le **Lasso** offre des performances similaires à Ridge, tout en ayant l'avantage d'un modèle plus parcimonieux (moins de variables)

Un résultat intéressant est que les variables éliminées par Lasso étaient généralement celles qui avaient les p-values les plus élevées dans le modèle MCO, confirmant que Lasso réalise bien une sélection cohérente des variables les plus informatives.

5.4 Choix du modèle optimal

Face à ces résultats, quel modèle privilégier ? La réponse dépend de l'objectif.

5.4.1 Pour l'interprétation économique

Le modèle **MCO** reste préférable car :
— Les coefficients ont une interprétation directe et non biaisée
— Les tests statistiques standard (tests t, tests F) sont valides
— La littérature académique utilise majoritairement les MCO

5.4.2 Pour la prédiction de prix

Le modèle **Lasso** offre le meilleur compromis car :

— Il améliore légèrement la précision prédictive
— Il est plus parcimonieux (moins de variables)
— Il réduit le risque de sur-ajustement

5.4.3 Compromis

Le modèle **Ridge** se situe entre les deux : il améliore les prédictions mais conserve toutes les variables. Il peut être préféré si on souhaite garder toutes les variables pour des raisons théoriques.

Dans la pratique, une stratégie raisonnable consiste à présenter le modèle MCO dans l'analyse principale (pour l'interprétation) tout en mentionnant que les modèles régularisés confirment la robustesse des résultats et offrent de meilleures performances prédictives.

5.5 Conclusion de la Partie 4

Les méthodes de régularisation (Ridge et Lasso) constituent des outils puissants pour améliorer les performances prédictives. Dans notre analyse :

— Amélioration modeste mais réelle (RMSE réduit de 2-3%)
— Le Ridge offre les meilleures performances (RMSE = 198,3 k)
— Le Lasso présente l'avantage supplémentaire de la sélection de variables

Ces résultats suggèrent que pour des applications pratiques d'estimation immobilière, le modèle Lasso serait le choix optimal, tandis que pour une analyse académique, le modèle MCO reste l'outil de référence.

6 Conclusion et recommandations

6.1 Synthèse des résultats

Cette étude a analysé les déterminants des prix immobiliers à partir d'un échantillon de 150 appartements, en utilisant des méthodes économétriques progressivement plus sophistiquées.

6.1.1 Résultats principaux

Le modèle de régression multiple explique 78,9% de la variance des prix. Les principaux déterminants identifiés sont :

— **Surface** : +4 390 par m² supplémentaire ($p < 0,001$)
— **Chambres** : +33 900 par chambre ($p = 0,001$)
— **Distance au centre** : -6 140 par km ($p < 0,001$)
— **Ascenseur** : +55 500 si présent ($p = 0,002$)
— **Étage** : +12 300 par étage ($p = 0,016$)
— **Année de construction** : +1 600 par année ($p = 0,037$)

Les tests diagnostiques valident la robustesse du modèle : absence de multicolinéarité, d'hétéroscédasticité et d'autocorrélation. Le test de Chow révèle cependant une rupture structurelle significative après 2020 ($F = 7,28$, $p < 0,001$).

Les méthodes de régularisation améliorent légèrement les performances prédictives, avec le Ridge offrant le meilleur RMSE (198,3 k).

6.2 Limites de l'analyse

Plusieurs limites importantes doivent être reconnues :

1. **Taille de l'échantillon** : 150 observations est relativement modeste, limitant la puissance statistique
2. **Endogénéité non résolue** : Sans instruments valides, nous ne pouvons pas affirmer que les relations identifiées sont causales
3. **Variables manquantes** : Proximité des transports, criminalité, qualité environnementale, état du bien, parking
4. **Rupture structurelle** : Le modèle unique n'est pas optimal pour toute la période
5. **Analyse transversale** : Impossibilité d'étudier la dynamique temporelle

6.3 Recommandations pour la pratique

6.3.1 Pour les acheteurs et vendeurs

Les trois facteurs les plus déterminants sont la surface, le nombre de chambres et la distance au centre-ville. Un acheteur cherchant à maximiser son rapport qualité-prix devrait privilégier les biens situés à moyenne distance du centre (10-20 km). La présence d'un ascenseur ajoute 55 500 , ce qui devrait être prioritaire dans les immeubles de plus de 3 étages.

6.3.2 Pour les professionnels de l'immobilier

Le modèle Lasso peut servir de base pour un outil d'estimation automatique des prix avec un R^2 de prédiction de près de 80%. La rupture structurelle post-COVID implique que les grilles d'estimation utilisées avant 2020 doivent être révisées.

6.3.3 Pour les décideurs publics

La forte décote liée à la distance au centre (-6 140 par km) reflète l'importance de l'accessibilité urbaine. Les politiques d'aménagement devraient renforcer les transports en commun vers la périphérie.

6.3.4 Pour de futures recherches

Plusieurs pistes d'amélioration sont identifiables :
- Collecter des variables instrumentales valides
- Constituer un échantillon plus large
- Exploiter des données de panel
- Approfondir l'analyse de la rupture COVID
- Intégrer des variables géospatiales précises

6.4 Mot de conclusion

Cette étude a démontré que les méthodes économétriques permettent d'identifier et de quantifier de manière robuste les principaux déterminants des prix immobiliers. Le modèle développé explique près de 80% de la variabilité des prix et offre des performances prédictives satisfaisantes.

Au-delà de ses résultats spécifiques, ce travail illustre la démarche économétrique complète : de l'analyse descriptive initiale aux tests diagnostiques sophistiqués, en passant par les méthodes de régularisation modernes. Cette approche méthodique est essentielle pour produire des analyses fiables et utiles à la décision.

A Annexes

A.1 Tableaux complets

Table 8 – Statistiques descriptives des variables du modèle (N=150)

Variable	Mean	Median	Std	Min	Max	Skewness	Kurtosis
Prix (k€)	2107.90	2105.05	229.92	1500.77	2743.04	0.16	-0.47
Surface (m^2)	116.71	117.85	37.69	15.21	218.53	0.05	-0.11
Chambres	2.89	3.00	1.08	1.00	5.00	0.10	-0.69
Distance centre (km)	16.50	16.87	9.02	0.83	29.99	-0.14	-1.19
Revenu médian (k€)	63.67	63.45	9.30	42.90	83.90	0.05	-0.58

Source : Données immobilières (N=150). Skewness et Kurtosis indiquent des distributions quasi-normales.

Table 9 – Corrélations de Pearson entre variables explicatives et Prix

Variable	Corrélation avec Prix
Surface (m^2)	0.827***
Chambres	0.615***
Qualité école	0.254**
Année vente	0.237**
Revenu médian quartier	0.206**
Étage	0.128*
Année construction	0.068
Ascenseur	0.038
Distance université	-0.125
Distance centre (km)	-0.307***

* p<0.05 ** p<0.01 *** p<0.001

Table 10 – Régression linéaire simple : Prix = f(Surface)

Variable	Coef.	SE	t-stat	p-value	IC 2.5%	IC 97.5%
Intercept	1519.37***	34.58	43.93	< 0.001	1451.03	1587.72
Surface (m^2)	5.04***	0.28	17.88	< 0.001	4.49	5.60

$R^2 = 0.683$ R^2 ajusté = 0.681 F-statistic = 319.6 $p < 0.001$
Durbin-Watson = 2.136 Jarque-Bera = 1.173 (p=0.556)

*** $p < 0.001$. Le modèle explique 68% de la variance du Prix.

Table 11 – Régression linéaire multiple : modèle complet (MCO)

Variable	Coef.	SE	t-stat	p-value	IC 2.5%	IC 97.5%
Intercept	-1679.49	1535.67	-1.09	0.276	-4715.04	1356.06
Surface (m^2)	4.39***	0.29	15.01	< 0.001	3.81	4.97
Chambres	33.92***	10.23	3.32	0.001	13.70	54.14
Année construction	1.61*	0.77	2.10	0.037	0.10	3.12
Distance centre (km)	-6.14***	0.99	-6.19	< 0.001	-8.11	-4.18
Étage	12.25*	5.05	2.43	0.016	2.27	22.23
Ascenseur	55.51**	17.92	3.10	0.002	20.09	90.94

$R^2 = 0.789$ R^2 ajusté $= 0.780$ F-statistic $= 88.94$ $p < 0.001$
Durbin-Watson $= 2.121$ AIC $= 1837$ BIC $= 1858$ N $= 150$

* p<0.05 ** p<0.01 *** p<0.001

Table 12 – Diagnostic de multicolinéarité : facteurs d'inflation de la variance

Variable	VIF	Interprétation
Surface (m^2)	1.56	Acceptable
Chambres	1.56	Acceptable
Année construction	1.03	Excellent
Distance centre (km)	1.02	Excellent
Étage	1.01	Excellent
Ascenseur	1.03	Excellent

Seuil critique : VIF < 10. Aucun problème de multicolinéarité détecté.

graphicx float

TABLE 13 – Comparaison des modèles selon le critère du R^2 ajusté

Spécification	R^2 ajusté	AIC	BIC
Linéaire (Prix $\sim$ X)	0.7798	1837	1858
Semi-log (log Prix $\sim$ X)	**0.7829**	**-460.2**	**-439.1**
Log-log (log Prix $\sim$ log X)	0.7443	-911.4	-890.3

Le modèle semi-log offre le meilleur compromis (R^2 maximal + AIC minimal).

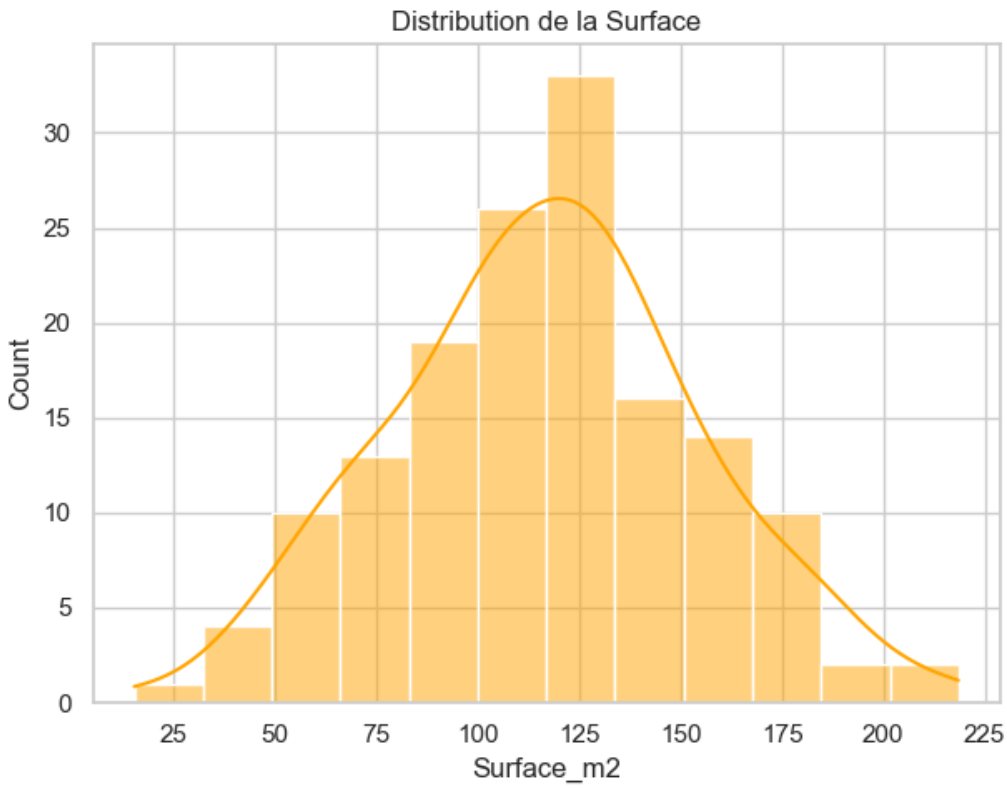

FIGURE 1 – Distribution de la surface (m^2).

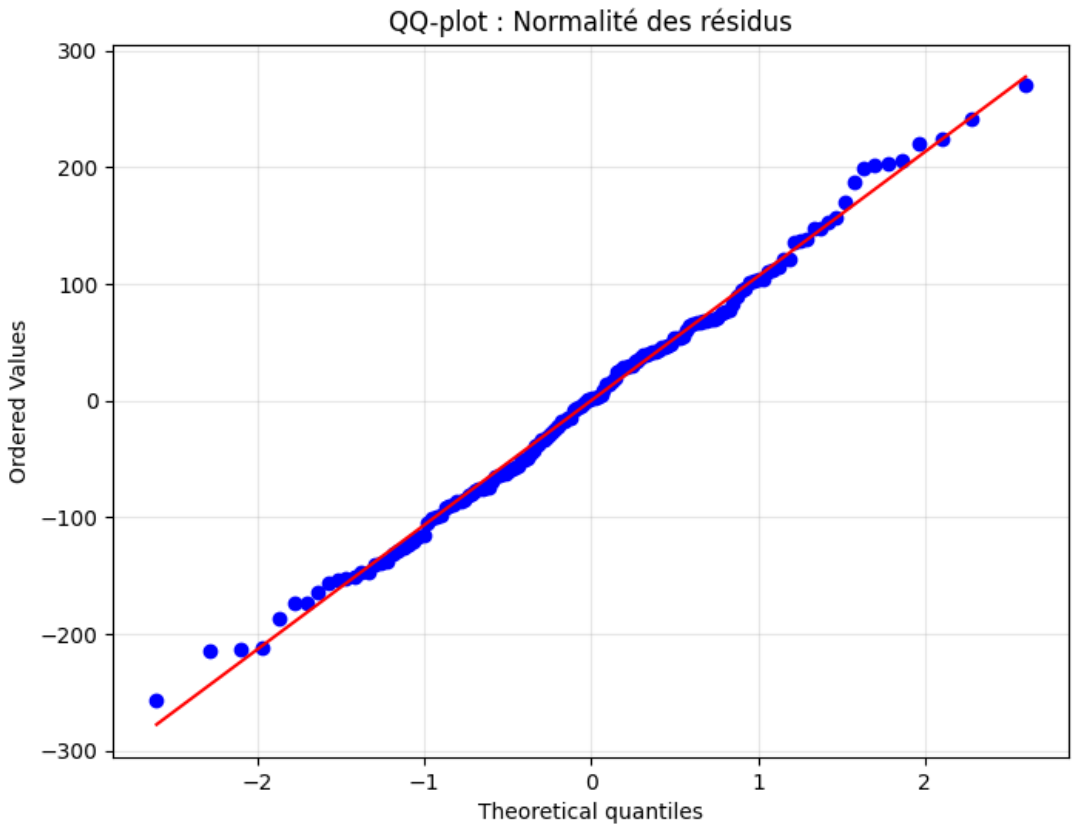

FIGURE 2 – QQ-plot : normalité des résidus.

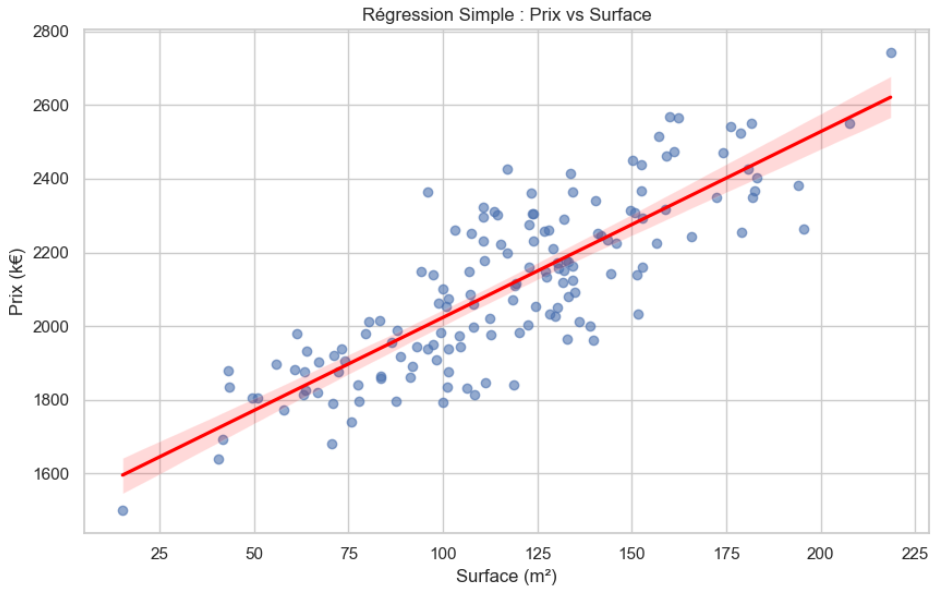

FIGURE 3 – Régression simple : prix vs surface.

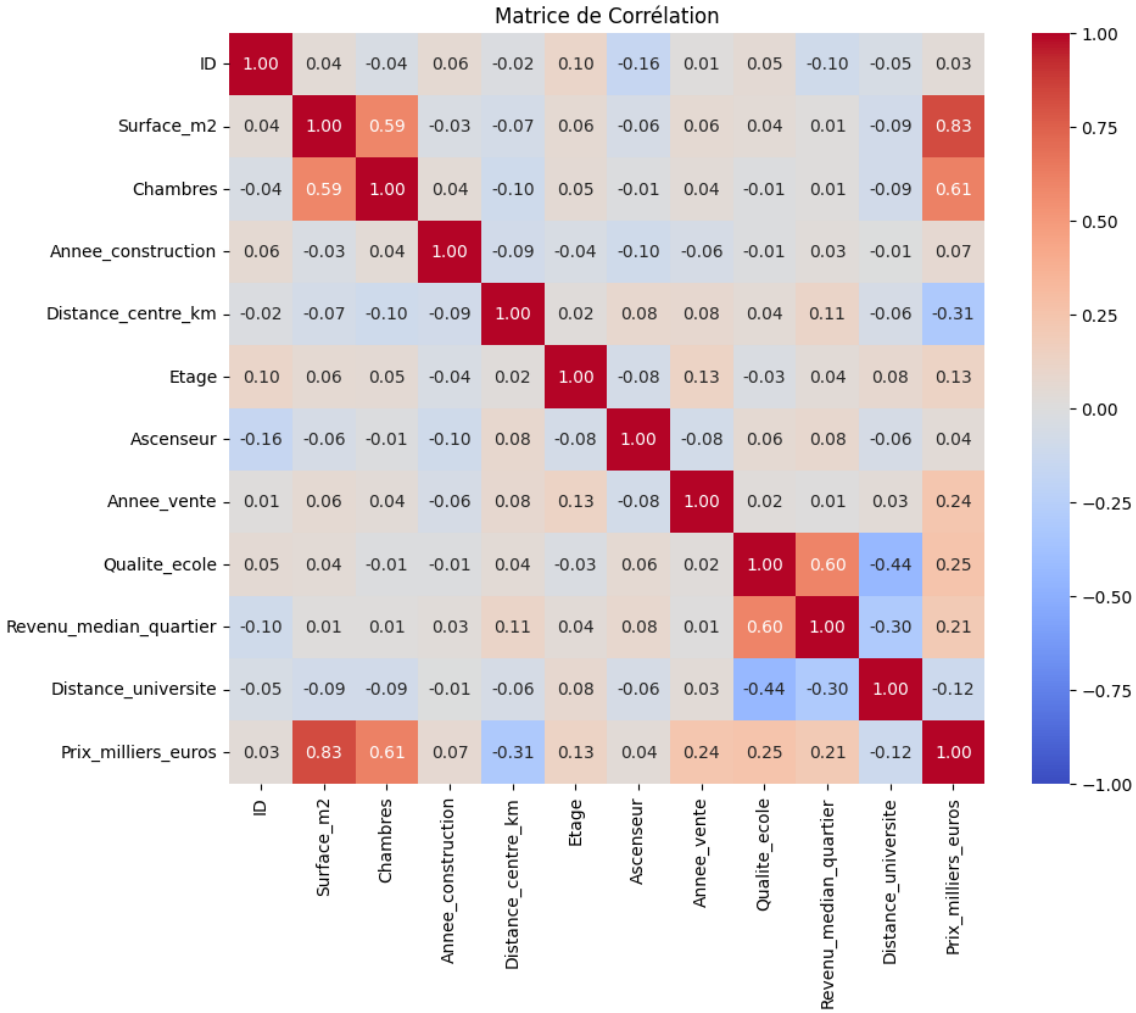

FIGURE 4 – Matrice de corrélation des variables.

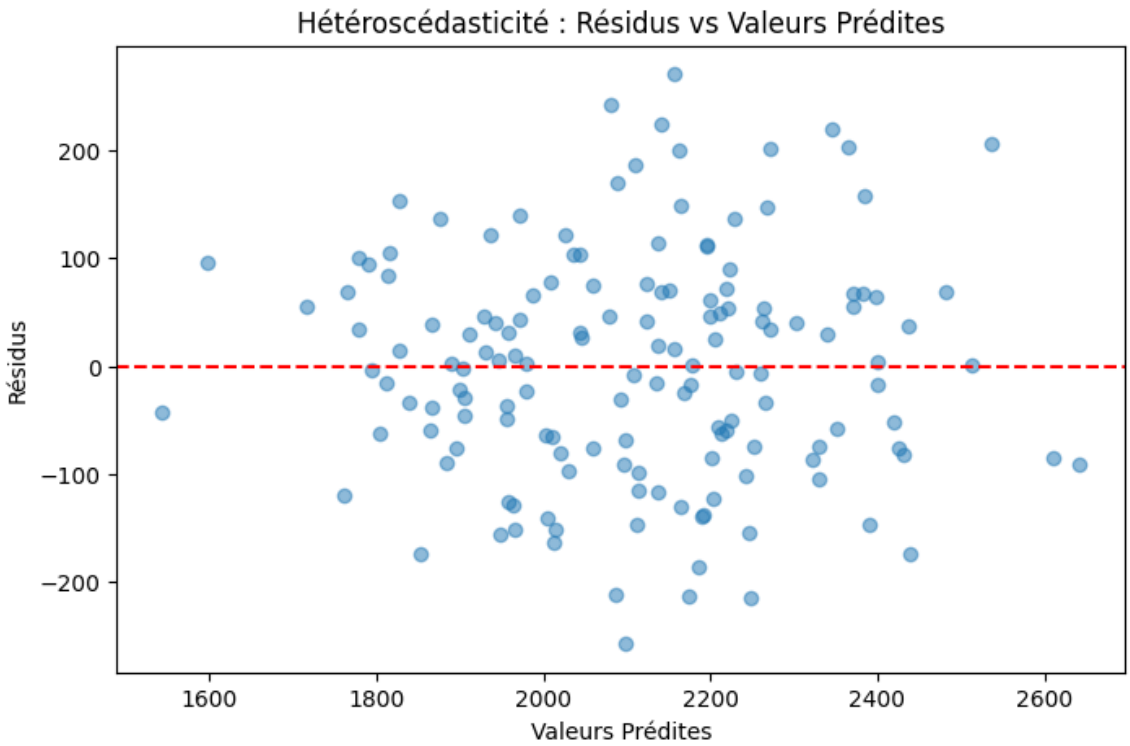

FIGURE 5 – Résidus vs valeurs prédites (diagnostic d'hétéroscédasticité).

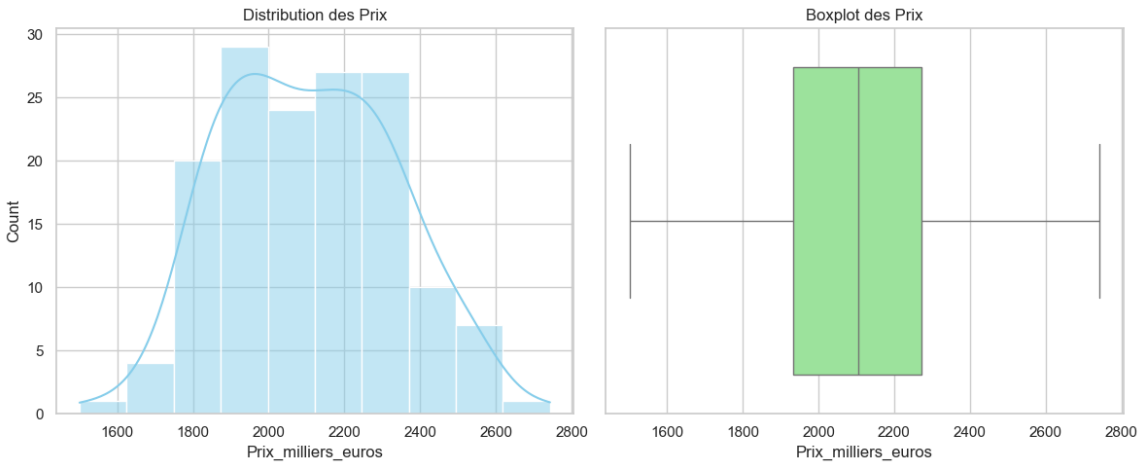

FIGURE 6 – Graphiques descriptifs (1).

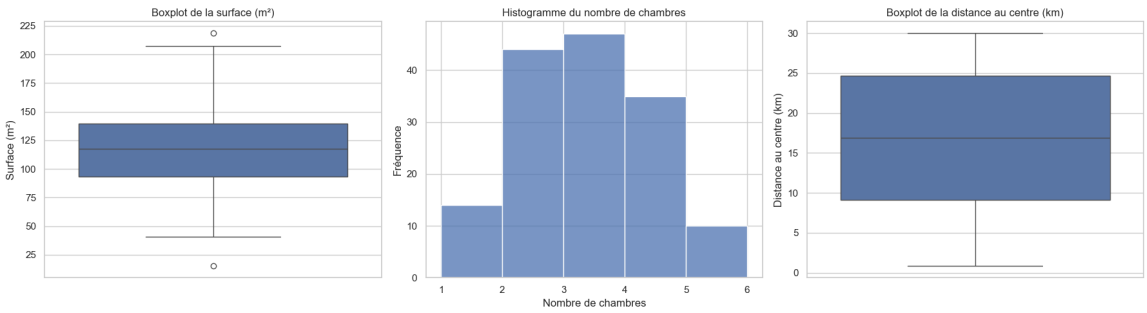

FIGURE 7 – Graphiques descriptifs (2).

A.2 Note méthodologique

Les analyses ont été réalisées avec Python 3.10, en utilisant les bibliothèques suivantes :

- `pandas` pour la manipulation et le nettoyage des données
- `numpy` pour les calculs numériques
- `matplotlib.pyplot` et `seaborn` pour les visualisations graphiques
- `statsmodels.formula.api` et `statsmodels.api` pour les régressions linéaires (MCO)
- `statsmodels.stats.outliers_influence` pour le calcul des facteurs d'inflation de variance (VIF)
- `statsmodels.stats.stattools` pour le test de Durbin-Watson (autocorrélation)
- `statsmodels.stats.diagnostic` pour le test de Breusch-Pagan (hétéroscédasticité)
- `scipy.stats` pour les tests de normalité (Jarque-Bera) et les calculs de probabilités
- `sklearn.model_selection` pour la séparation des échantillons (train/test split)
- `sklearn.preprocessing` pour la standardisation des variables (StandardScaler)
- `sklearn.linear_model` pour les méthodes de régularisation (Ridge, Lasso, RidgeCV, LassoCV)
- `sklearn.metrics` pour l'évaluation des modèles (RMSE, R^2)