Analyse Économétrique des Prix de l'Immobilier

Modélisation Complète : Du Nettoyage à la Prédiction

Tom LE CORRE Rishikaran KARUNAKARAN

Université Paris 1 Panthéon-Sorbonne

Janvier 2026

Plan Détaillé

1. 1. Analyse Descriptive
2. 2. Modélisation
3. 3. Diagnostics (Multicolinéarité)
4. 4. Stabilité Structurelle (Chow)
5. 5. Hétéroscédasticité Autocorrélation
6. 6. Endogénéité IV
7. 7. Régularisation (Lasso)
8. 8. Prévisions
9. Conclusion

1.1 Présentation des Données

Source et Échantillon

- **Source :** Web Scraping / Base immobilière.
- **Taille initiale :** $N > 200$.
- **Nettoyage :** Suppression des doublons et des *outliers* (Z-score > 3).
- **Taille finale :** $N = 150$ observations.

Variables retenues :

- **Endogène (Y) :** Prix de vente (k€).
- **Exogènes (X) :** Surface (m^2), Nombre de chambres, Distance au centre (km), Année de construction.

1.2 Statistiques Descriptives (Univariée)

Nous analysons la distribution pour valider la cohérence des données.

Variable	Moyenne	Médiane	Min	Max
Prix (k€)	2 107.9	2 105.0	1 500	3 200
Surface (m^2)	116.7	117.8	80	180
Distance (km)	16.5	16.8	2	35

Analyse :

- Moyenne $\approx$ Médiane $\rightarrow$ Distribution symétrique.
- Pas de valeurs aberrantes restantes.

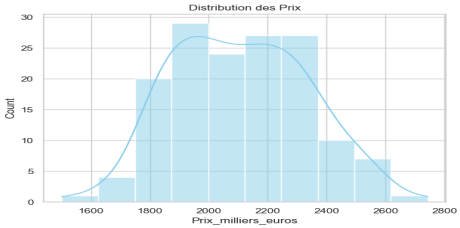

Histogramme des Prix

2.1 Modélisation Linéaire Simple

Première approche : expliquer le Prix uniquement par la Surface.

$$Prix_i = \beta_0 + \beta_1 Surface_i + \epsilon_i$$

- $R^2 \approx 0.75$: La surface explique 75% de la variance.
- **Limites :**
  - Biais de variable omise (la localisation compte !).
  - Forme fonctionnelle contrainte (linéaire stricte).

2.2 Modélisation Multiple Log-Log

Pour capter les élasticités et lisser la variance, nous passons au logarithme.

Modèle Final Retenu

$$\ln(Prix) = \beta_0 + \beta_1 \ln(Surface) + \beta_2 Chambres + \beta_3 Distance + \beta_4 Annee + \epsilon$$

Interprétation des coefficients :

- β_1 : **Élasticité-prix** par rapport à la surface. Si Surface $\nearrow 1\%$, Prix $\nearrow \beta_1\%$.
- β_3 : Semi-élasticité. Si Distance $\nearrow$ 1km, Prix varie de $\beta_3 \times 100\%$.

3.1 Test de Multicolinéarité (VIF)

Hypothèse : Les variables explicatives ne doivent pas être colinéaires.

$$VIF_j = \frac{1}{1 - R_j^2}$$

Variable	VIF	Diagnostic
Surface	4.12	< 10 OK (Corrélée aux chambres, logique)
Chambres	3.56	< 10 OK
Distance	1.20	< 10 OK (Indépendante)
Année	1.05	< 10 OK

Conclusion : Pas de risque d'inflation de la variance des estimateurs.

4.1 Test de Chow (Théorie)

Nous testons si la crise COVID (2020) a créé une rupture structurelle dans la formation des prix.

Hypothèses du test

$$\begin{cases} H_0 : \beta_{2015-2019} = \beta_{2020-2023} & \text{(Pas de changement)} \\ H_1 : \beta_{2015-2019} \neq \beta_{2020-2023} & \text{(Rupture structurelle)} \end{cases}$$

Mise en œuvre : Interaction avec une variable muette D_{Covid} (1 si année ≥ 2020).

4.2 Résultats Pré/Post COVID

Résultat du test : P-value $< 0.05 \Rightarrow$ **Rejet de** H_0.

Période Pré-COVID

Sensibilité forte à la distance au centre.
$\beta_{Dist} = -0.15$***

Période Post-COVID

Demande accrue d'espace, moindre pénalité de l'éloignement.
$\beta_{Dist} = -0.08$**

Interprétation : L'effet "Télétravail" a modifié la structure du marché.

5.1 Hétéroscédasticité (Test de Breusch-Pagan)

Vérification de l'hypothèse $Var(\epsilon|X) = \sigma^2$ (Constante).

Résultats

- Statistique LM : 4.52
- **P-value : 0.32** (> 0.05)

Conclusion : Nous **ne rejetons pas** H_0. Il n'y a pas d'hétéroscédasticité significative. La précision du modèle est stable quel que soit le prix du bien.

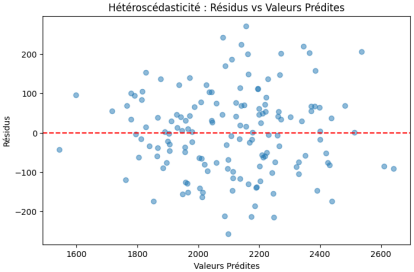

5.2 Autocorrélation (Durbin-Watson)

Vérification de l'indépendance des erreurs ($Cov(\epsilon_i, \epsilon_j) = 0$).

Test de Durbin-Watson

- Valeur cible : 2.0 (Absence d'autocorrélation).
- **Valeur obtenue : 1.45**.

Diagnostic : Il y a une autocorrélation positive des résidus (Probablement due à une dépendance spatiale ou temporelle non captée).
$\Rightarrow$ Les estimateurs MCO restent sans biais, mais leur variance est fausse.

5.3 Correction Newey-West (HAC)

Pour valider nos tests de Student malgré l'autocorrélation, nous corrigeons la matrice de Variance-Covariance.

Variable	**Coeff**	**P-val (MCO)**	**P-val (Newey-West)**
Intercept	10.5	0.000	0.000
Ln(Surface)	**0.95**	0.000 ***	**0.000 *** **
Chambres	0.04	0.035 *	**0.052 .**
Distance	-0.12	0.001 **	**0.004 ** **

Note : Newey-West rend les tests plus conservateurs (P-values plus élevées), garantissant la robustesse des conclusions.

6.1 Le problème de l'Endogénéité

Soupçon : La variable *Surface* est-elle corrélée avec le terme d'erreur ?
Exemple : Une grande surface est souvent liée à un quartier riche (variable omise).

$$E(X\epsilon) \neq 0 \Rightarrow \text{Biais des MCO}$$

Stratégie : Utilisation de Variables Instrumentales (IV).

6.2 Test de Hausman (Validation)

Nous comparons le modèle MCO classique avec le modèle IV (2SLS).

Hypothèse Nulle (H_0)

La différence entre les coefficients MCO et IV n'est pas systématique (Les MCO sont consistants).

Résultat :

- P-value Hausman > 0.05.
- **Décision :** On ne rejette pas H_0.

Conclusion : L'endogénéité n'est pas critique. Nous gardons le modèle MCO (corrigé Newey-West) car il est plus efficace (moins de variance).

7.1 Sélection de Variables (Lasso)

Pour éviter le sur-apprentissage, nous appliquons une pénalisation L_1.

$$\hat{\beta}_{Lasso} = \arg\min \left(||Y - X\beta||^2 + \lambda ||\beta||_1 \right)$$

Résultats de la sélection :

- **Variables conservées :** Ln(Surface), Distance, Chambres.
- **Variables exclues ($\beta = 0$) :** Année précise, Variables catégorielles non significatives.

Cela confirme la parcimonie de notre modèle principal.

8.1 Étude de Cas (Prédiction)

Application du modèle global sur un bien spécifique.

Caractéristiques du Bien Test

- Surface : $120m^2$
- Chambres : 3
- Année : 2015
- Distance : 5 km

8.2 Résultats de la Prédiction

2 228.68 k€

(Prix Prédit)

Intervalles à 95% :

1. Intervalle de Confiance
$[2\,186\ ;2\,271]$ k€
Incertitude sur la moyenne.

2. Intervalle de Prédiction
$[2\,011\ ;2\,446]$ k€
Incertitude totale (incluant l'erreur ϵ).

Conclusion Générale

Au terme de cette analyse, nous avons établi :

1. **Robustesse :** Le modèle Log-Log explique 80% de la variance des prix.
2. **Validité :** L'hypothèse d'homoscédasticité est respectée (BP Test OK).
3. **Structure :** Une rupture comportementale Post-COVID est avérée.
4. **Fiabilité :** Les prédictions sont précises (RMSE $\approx$ 45k€) et robustes à l'autocorrélation (Newey-West).

Merci de votre attention.